

Note: Phổ của Perron–Frobenius operator, các thuật toán DMD/EDMD/GEDMD và Koopman mode decomposition

Mục lục

1	Giới thiệu	3
2	Nhắc lại: Koopman và Perron–Frobenius	4
2.1	Hệ động lực học rời rạc	4
2.2	Koopman operator	4
2.3	Perron–Frobenius operator	4
2.4	Tính đối ngẫu	5
3	Phổ của Perron–Frobenius operator và ý nghĩa của eigenvalue 1	5
3.1	Vì sao eigenvalue 1 là đặc biệt?	5
3.2	Có luôn tồn tại eigenvalue 1?	5
4	Ví dụ 1: hệ $\dot{x} = -x$	5
4.1	Động lực học	5
4.2	Điều gì xảy ra với một phân bố điểm ban đầu?	6
5	Ví dụ 2: logistic map	6
5.1	Động học điểm là phức tạp, nhưng động học phân bố lại đơn giản	6
5.2	Ý nghĩa	7
5.3	Diễn giải về số lượng eigenvalue 1	7
6	Ví dụ 3: hệ có nhiều miền hút	7
6.1	Hệ có hai điểm cân bằng ổn định	7
6.2	Steady-state dynamics	7
6.3	Kết luận	7
7	Ý nghĩa phổ của PF operator ngoài eigenvalue 1	7

8	Một nhận xét quan trọng về computation và differential geometry	8
9	Mục tiêu computation: xấp xỉ các toán tử từ dữ liệu	8
10	Dynamic Mode Decomposition (DMD)	9
10.1	Dữ liệu vào	9
10.2	Bài toán	9
10.3	Bài toán tối ưu	9
10.4	Tính bằng SVD	10
10.5	Eigenvalues và modes	10
10.6	Ý nghĩa của DMD	10
11	POD/SVD so với DMD	10
11.1	POD/SVD làm gì?	10
11.2	Nhược điểm	11
11.3	Vai trò của DMD	11
12	Extended DMD (EDMD)	11
12.1	Vì sao cần EDMD?	11
12.2	Dictionary of observables	11
12.3	Dữ liệu lifted	11
12.4	Bài toán EDMD	12
12.5	Dạng thực hành phổ biến hơn	12
12.6	Eigenfunctions xấp xỉ của Koopman	12
12.7	Một cảnh báo ký hiệu rất quan trọng	13
13	Generator EDMD (GEDMD)	13
13.1	Động lực học liên tục	13
13.2	Dữ liệu cần có	13
13.3	Dictionary và đạo hàm dictionary	13
13.4	Bài toán least-squares cho generator	14
14	Sai số xấp xỉ và hai nguồn sai số chính	14
15	Koopman mode decomposition	15
15.1	Ý tưởng	15
15.2	Lợi thế lớn	15
15.3	Mở rộng nhờ tính đại số của eigenfunctions	15
16	Ứng dụng của Koopman mode decomposition	16
16.1	Propagation of uncertainty	16
16.2	Reachability	16

16.3 Safety	16
17 Xấp xỉ Perron–Frobenius từ Koopman	16
17.1 Trường hợp basis trực giao	16
17.2 Trường hợp basis không trực giao	17
18 Ví dụ Van der Pol oscillator và invariant measure	17
18.1 Động lực học	17
18.2 PF eigenfunction ứng với eigenvalue 1	17
18.3 Thông tin thời gian nằm trong measure không đều	17
19 Ergodicity và physical measure	18
19.1 Time average và space average	18
19.2 Không phải measure nào ergodic cũng “có ý nghĩa vật lý”	18
19.3 Với Van der Pol	18
20 Occupation measure	18
21 Tại sao operator framework hữu ích cho control?	19
22 Tóm tắt thuật toán	19
22.1 DMD	19
22.2 EDMD	19
22.3 GEDMD	20
23 Những điểm tư tưởng cốt lõi cần nhớ	20
24 Kết luận	21

1. Giới thiệu

Trong chuỗi bài giảng về operator-theoretic methods for dynamical systems and control, hai toán tử tuyến tính vô hạn chiều đóng vai trò trung tâm là:

- **Koopman operator**: tác động lên *observables* (hàm của trạng thái),
- **Perron–Frobenius (PF) operator**: tác động lên *densities* hay phân bố xác suất/khối lượng trên không gian trạng thái.

Ý tưởng cốt lõi là:

dù hệ động lực gốc là phi tuyến trong không gian trạng thái, ta có thể mô tả nó bằng một **toán tử tuyến tính** trong không gian hàm.

Trong phần trước, phổ của Koopman operator được nhấn mạnh vì các eigenfunction của nó có thể đóng vai trò như một phép đổi tọa độ, từ đó đưa động lực học phi tuyến về một dạng tuyến tính trong không gian hàm.

Trong bài này, ta tiếp tục bàn về:

1. ý nghĩa phổ của **Perron–Frobenius operator**,
2. ý nghĩa đặc biệt của eigenfunction ứng với eigenvalue 1,
3. cách **xấp xỉ các toán tử này từ dữ liệu** bằng DMD, EDMD, GEDMD,
4. khái niệm **Koopman mode decomposition**,
5. kết nối với **invariant measures, ergodicity, occupation measure**,
6. và hàm ý cho điều khiển, an toàn, và reachable sets.

2. Nhắc lại: Koopman và Perron–Frobenius

2.1. Hệ động lực học rời rạc

Xét một hệ rời rạc:

$$x_{k+1} = T(x_k), \quad x_k \in \mathcal{X} \subset \mathbb{R}^n. \quad (1)$$

Ở đây:

- T là ánh xạ động lực học,
- x_k là trạng thái tại thời điểm k .

2.2. Koopman operator

Định nghĩa 1. Cho một observable $g : \mathcal{X} \rightarrow \mathbb{C}$. Koopman operator $\mathcal{K}$ được định nghĩa bởi

$$(\mathcal{K}g)(x) = g(T(x)). \quad (2)$$

Đây là toán tử tác động lên hàm chứ không tác động trực tiếp lên trạng thái.

2.3. Perron–Frobenius operator

Trong khi Koopman đẩy *hàm quan sát* đi tới trước, thì Perron–Frobenius operator đẩy *density* hoặc *measure* đi tới trước theo động lực học của hệ.

Nếu ρ là một mật độ trên không gian trạng thái, thì PF operator $\mathcal{P}$ cho ta mật độ mới sau khi hệ tiến hóa một bước. Hiểu đơn giản:

Koopman nói observable biến đổi như thế nào; còn Perron–Frobenius nói phân bố điểm trong không gian trạng thái biến đổi như thế nào.

2.4. Tính đối ngẫu

Hai toán tử này là **đối ngẫu** của nhau. Trong ngữ cảnh hữu hạn chiều, phép đối ngẫu này hiện ra như phép chuyển vị ma trận.

Ý tưởng này sẽ quay lại rõ ràng khi ta xây dựng các xấp xỉ hữu hạn chiều:

$$P \approx K^\top$$

khi cơ sở là trực giao.

3. Phổ của Perron–Frobenius operator và ý nghĩa của eigenvalue 1

3.1. Vì sao eigenvalue 1 là đặc biệt?

Vì PF operator đẩy mật độ đi tới trước theo thời gian, nên một mật độ ρ^* thỏa

$$\mathcal{P}\rho^* = \rho^*$$

chính là một **steady-state distribution** hay **invariant density**.

Nói cách khác, ρ^* là eigenfunction của PF ứng với eigenvalue 1:

$$\mathcal{P}\rho^* = 1 \cdot \rho^*. \quad (3)$$

Do đó:

eigenfunction của Perron–Frobenius ứng với eigenvalue 1 mã hóa động học trạng thái dừng của hệ.

Đây là ý chính đầu tiên và quan trọng nhất của bài giảng.

3.2. Có luôn tồn tại eigenvalue 1?

Trong nhiều hệ động lực học tắt định có ý nghĩa vật lý, PF operator luôn có ít nhất một eigenvalue bằng 1. Điều này phản ánh sự tồn tại của ít nhất một steady-state distribution hoặc invariant measure.

4. Ví dụ 1: hệ $\dot{x} = -x$

4.1. Động lực học

Xét hệ liên tục một chiều:

$$\dot{x} = -x. \quad (4)$$

Đây là hệ tuyến tính ổn định toàn cục. Nghiệm của nó là

$$x(t) = x(0)e^{-t},$$

nên mọi quỹ đạo đều hội tụ về 0.

4.2. Điều gì xảy ra với một phân bố điểm ban đầu?

Giả sử ban đầu ta có một phân bố xác suất hoặc một đám điểm trên trục số. Khi cho hệ tiến hóa theo thời gian:

- mọi điểm đều hội tụ về 0,
- vì thế toàn bộ phân bố sẽ co lại về gốc,
- trong nghĩa phân phối, nó hội tụ về một **Dirac delta measure** tại $x = 0$.

Ký hiệu:

$$\rho_t \rightarrow \delta_0 \quad \text{khi } t \rightarrow \infty.$$

Do đó, steady-state distribution của hệ này chính là δ_0 . Nói bằng ngôn ngữ PF:

eigenfunction/eigenmeasure ứng với eigenvalue 1 của PF operator mang thông tin về phân bố dừng, ở đây là Dirac delta tập trung tại gốc.

Nhận xét 1. Điểm tĩnh tế ở đây là *steady-state object* nhiều khi không phải là một hàm trơn, mà là một **distribution** theo nghĩa giải tích hàm.

5. Ví dụ 2: logistic map

5.1. Động học điểm là phức tạp, nhưng động học phân bố lại đơn giản

Một trong những ví dụ hay nhất là logistic map ở chế độ hỗn loạn:

$$x_{k+1} = rx_k(1 - x_k).$$

Quan sát điểm-thành-điểm của logistic map có thể rất phức tạp, thậm chí chaotic. Nhưng nếu thay vì theo dõi một điểm riêng lẻ, ta theo dõi **một phân bố điểm** và cho phân bố ấy tiến hóa, thì sau đủ lâu nó có thể hội tụ về một density ổn định rất đẹp.

Density giới hạn này chính là:

$$\mathcal{P}\rho^* = \rho^*. \quad (5)$$

Nghĩa là nó là eigenfunction của PF operator ứng với eigenvalue 1.

5.2. Ý nghĩa

Điều này cho thấy một triết lý quan trọng:

pointwise dynamics có thể hỗn loạn và rất khó hiểu, nhưng distributional dynamics trong function space lại có thể rất có cấu trúc.

5.3. Diễn giải về số lượng eigenvalue 1

Nếu một hệ, bất kể phân bố ban đầu nào, đều hội tụ về cùng một steady-state distribution, thì trực giác là PF operator chỉ có **một** steady-state mode thống trị, tức là một eigenvalue 1 tương ứng với phân bố dừng đó.

6. Ví dụ 3: hệ có nhiều miền hút

6.1. Hệ có hai điểm cân bằng ổn định

Xét một hệ có hai equilibrium ổn định, mỗi equilibrium có một miền hút riêng. Khi đó:

- nếu trạng thái ban đầu thuộc miền hút thứ nhất, quỹ đạo đi tới equilibrium thứ nhất;
- nếu trạng thái ban đầu thuộc miền hút thứ hai, quỹ đạo đi tới equilibrium thứ hai.

6.2. Steady-state dynamics

Steady-state dynamics của hệ lúc này không chỉ gồm một điểm, mà gồm **hai** điểm cân bằng ổn định. Theo quan điểm PF:

- có một steady-state distribution tương ứng với delta measure tại equilibrium thứ nhất,
- có một steady-state distribution tương ứng với delta measure tại equilibrium thứ hai.

Vì vậy, PF operator có thể có **nhiều eigenfunction ứng với eigenvalue 1**.

6.3. Kết luận

Số lượng eigenvalue 1 của PF operator mang thông tin về số lượng steady-state distributions của hệ.

7. Ý nghĩa phổ của PF operator ngoài eigenvalue 1

Vì PF operator là toán tử vô hạn chiều, ngoài mode ứng với eigenvalue 1, nó còn có các mode khác với các eigenvalue khác. Những mode này chứa thông tin về:

- tốc độ hội tụ đến trạng thái dừng,

- cấu trúc metastable,
- limit cycles,
- các hành vi lâu dài phức tạp khác.

Tuy nhiên, trong rất nhiều ứng dụng, eigenfunction ứng với eigenvalue 1 là đối tượng quan trọng nhất vì nó mã hóa invariant distribution / invariant measure.

8. Một nhận xét quan trọng về computation và differential geometry

Bài giảng nhấn mạnh một điểm rất thú vị:

các phương pháp differential geometry trong điều khiển là rất đẹp, rất thanh lịch, nhưng thường khó tính toán trực tiếp và chủ yếu hữu ích cho các hệ có số chiều thấp.

Ví dụ, trong feedback linearization hoặc nonlinear change of coordinates:

- ta phải tính nhiều Lie derivatives,
- phải xây dựng explicit change of coordinates,
- và change of coordinates đó có thể không phải polynomial, thậm chí không phải rational.

Ngay cả khi vector field gốc là polynomial, phép đổi tọa độ đưa hệ về dạng tuyến tính có thể không có biểu thức đại số đơn giản.

Vì vậy, operator-theoretic computation mang một ưu điểm rất lớn:

thay vì cố gắng tìm công thức giải tích đẹp cho change of coordinates, ta chấp nhận tính toán trực tiếp từ dữ liệu.

9. Mục tiêu computation: xấp xỉ các toán tử từ dữ liệu

Bây giờ ta chuyển sang câu hỏi thực dụng nhất:

Nếu chỉ có dữ liệu của hệ động lực học, làm sao xây dựng một xấp xỉ hữu hạn chiều của Koopman hoặc PF operator?

Điểm then chốt là:

- Koopman và PF là **tuyến tính**,
- nên các thuật toán xấp xỉ cơ bản quy về **least-squares**.

Chính nhờ vậy mà dù lý thuyết nền phía sau rất sâu, computation cơ bản lại khá đơn giản về mặt thuật toán.

10. Dynamic Mode Decomposition (DMD)

10.1. Dữ liệu vào

Giả sử ta có time-series data

$$x_1, x_2, \dots, x_m, \quad x_k \in \mathbb{R}^n,$$

trong đó x_{k+1} là trạng thái sau một bước thời gian từ x_k .

Ta gom dữ liệu thành hai ma trận:

$$X = \begin{bmatrix} x_1 & x_2 & \cdots & x_{m-1} \end{bmatrix}, \quad X' = \begin{bmatrix} x_2 & x_3 & \cdots & x_m \end{bmatrix}. \quad (6)$$

Ở đây:

$$X, X' \in \mathbb{R}^{n \times (m-1)}.$$

10.2. Bài toán

Ta muốn tìm ma trận $A \in \mathbb{R}^{n \times n}$ sao cho

$$X' \approx AX. \quad (7)$$

Nói cách khác, ta tìm ánh xạ tuyến tính tốt nhất theo nghĩa least-squares mô tả quan hệ giữa các snapshots liên tiếp.

10.3. Bài toán tối ưu

$$A^* = \arg \min_A \|X' - AX\|_F^2. \quad (8)$$

Nghiệm least-squares là

$$A^* = X'X^\dagger, \quad (9)$$

trong đó $X^\dagger$ là pseudo-inverse của X .

Nếu dùng công thức chuẩn:

$$X^\dagger = X^\top (XX^\top)^{-1}$$

hoặc

$$X^\dagger = (X^\top X)^{-1} X^\top,$$

tùy cấu trúc và hạng của ma trận.

10.4. Tính bằng SVD

Trong thực hành, khi dữ liệu lớn, không nên tính pseudo-inverse theo công thức ngây thơ. Thay vào đó, ta lấy SVD:

$$X = U\Sigma V^*. \quad (10)$$

Khi đó:

$$X^\dagger = V\Sigma^{-1}U^*, \quad (11)$$

và do đó:

$$A^* = X'V\Sigma^{-1}U^*. \quad (12)$$

Đây là công thức DMD cơ bản.

10.5. Eigenvalues và modes

Sau khi có A^* , ta giải bài toán riêng:

$$A^*w = \lambda w. \quad (13)$$

Khi đó:

- λ : DMD eigenvalues,
- w : DMD modes / eigenvectors.

10.6. Ý nghĩa của DMD

DMD là một thuật toán:

- khai thác **cấu trúc thời gian** trong dữ liệu,
- tìm các mode quan trọng về mặt **động lực học**,
- khác với PCA/POD vốn chỉ nhấn mạnh năng lượng của dữ liệu.

11. POD/SVD so với DMD

11.1. POD/SVD làm gì?

Nếu chỉ xét một tập snapshots như một đám vector và bỏ qua thứ tự thời gian, thì SVD/POD tìm ra các mode quan trọng nhất từ góc nhìn **năng lượng**.

Điều này rất tốt cho data compression và dimension reduction.

11.2. Nhược điểm

Tuy nhiên, trong các hệ có động lực học tinh tế như turbulence:

- mode mang nhiều năng lượng nhất chưa chắc là mode quan trọng nhất về mặt động lực học,
- có những mode năng lượng nhỏ nhưng nằm gần trục $j\omega$, suy giảm chậm, nên mới là những mode quyết định hành vi dài hạn hoặc instability.

11.3. Vai trò của DMD

DMD khắc phục điểm này bằng cách giữ cấu trúc nhân quả $x_k \mapsto x_{k+1}$, nên mode thu được có ý nghĩa động lực học rõ hơn.

12. Extended DMD (EDMD)

12.1. Vì sao cần EDMD?

DMD thực chất vẫn hoạt động trong không gian trạng thái gốc. Điều đó tương đương với việc dùng các observable rất đơn giản, gần như chỉ là các tọa độ gốc.

Muốn xấp xỉ Koopman operator tốt hơn, ta cần **lift** dữ liệu lên một không gian observable giàu hơn.

12.2. Dictionary of observables

Chọn một thư viện các hàm:

$$\psi_i : \mathbb{R}^n \rightarrow \mathbb{R}, \quad i = 1, \dots, d. \quad (14)$$

Gom lại thành vector-valued lifting map:

$$\Psi(x) = \begin{bmatrix} \psi_1(x) \\ \psi_2(x) \\ \vdots \\ \psi_d(x) \end{bmatrix} \in \mathbb{R}^d. \quad (15)$$

Thông thường $d \geq n$, thường lớn hơn nhiều so với n .

12.3. Dữ liệu lifted

Từ các điểm dữ liệu $x_1, \dots, x_m$, ta xây dựng:

$$\Psi_X = \begin{bmatrix} \Psi(x_1) & \Psi(x_2) & \cdots & \Psi(x_{m-1}) \end{bmatrix}, \quad (16)$$

và

$$\Psi_{X'} = \begin{bmatrix} \Psi(x_2) & \Psi(x_3) & \cdots & \Psi(x_m) \end{bmatrix}. \quad (17)$$

12.4. Bài toán EDMD

Tìm ma trận $K \in \mathbb{R}^{d \times d}$ sao cho

$$\Psi_{X'} \approx K \Psi_X. \quad (18)$$

Least-squares:

$$K^* = \arg \min_K \|\Psi_{X'} - K \Psi_X\|_F^2. \quad (19)$$

Nghiệm:

$$K^* = \Psi_{X'} \Psi_X^\dagger. \quad (20)$$

12.5. Dạng thực hành phổ biến hơn

Một công thức rất phổ biến và hiệu quả số hơn là:

$$K = G^{-1} A, \quad (21)$$

trong đó

$$G = \frac{1}{m} \Psi_X \Psi_X^\top, \quad (22)$$

và

$$A = \frac{1}{m} \Psi_X \Psi_{X'}^\top. \quad (23)$$

Ở đây:

$$G, A \in \mathbb{R}^{d \times d}.$$

Nếu dictionary functions đủ độc lập tuyến tính và dữ liệu đủ “exciting”, thì G khả nghịch.

12.6. Eigenfunctions xấp xỉ của Koopman

Giải bài toán riêng:

$$K w_j = \lambda_j w_j. \quad (24)$$

Khi đó eigenfunction xấp xỉ của Koopman operator được cho bởi

$$\phi_j(x) \approx w_j^\top \Psi(x). \quad (25)$$

Đây là một trong những công thức quan trọng nhất của EDMD.

12.7. Một cảnh báo ký hiệu rất quan trọng

Tùy cách đặt vector observable là cột hay hàng, ma trận thu được có thể là K hoặc $K^\top$. Điều này không phải chi tiết nhỏ:

- nếu nhầm, ta có thể đang tính eigenfunctions của toán tử đối ngẫu,
- tức là lẫn giữa Koopman và Perron–Frobenius.

Vì vậy phải cực kỳ cẩn thận với convention trái/phải khi nhân ma trận và hàm cơ sở.

13. Generator EDMD (GEDMD)

13.1. Động lực học liên tục

Với hệ liên tục:

$$\dot{x} = f(x), \quad (26)$$

thay vì xấp xỉ trực tiếp Koopman operator $\mathcal{K}$, đôi khi ta muốn xấp xỉ **generator** của nó:

$$\mathcal{L}g = \nabla g(x)^\top f(x). \quad (27)$$

Điều này đặc biệt hữu ích trong control-affine systems, nơi cấu trúc liên tục theo thời gian thuận lợi hơn cho phân tích điều khiển.

13.2. Dữ liệu cần có

Ta cần dữ liệu dạng:

$$(x_\ell, \dot{x}_\ell), \quad \ell = 1, \dots, m.$$

Ở đây $\dot{x}_\ell$ có thể có được từ:

- mô phỏng,
- đạo hàm số,
- finite difference,
- hoặc các bộ ước lượng đạo hàm.

13.3. Dictionary và đạo hàm dictionary

Chọn lại dictionary:

$$\Psi(x) = \begin{bmatrix} \psi_1(x) \\ \vdots \\ \psi_d(x) \end{bmatrix}.$$

Tại điểm dữ liệu x_ℓ , ta định nghĩa

$$\dot{\psi}_k(x_\ell) := \sum_{j=1}^n \frac{\partial \psi_k}{\partial x_j} \dot{x}_{\ell,j}. \quad (28)$$

Tức là:

$$\dot{\psi}_k(x_\ell) = \nabla \psi_k(x_\ell)^\top \dot{x}_\ell.$$

Gom các giá trị đó lại thành ma trận:

$$\Psi_X = \begin{bmatrix} \Psi(x_1) & \cdots & \Psi(x_m) \end{bmatrix}, \quad \dot{\Psi}_X = \begin{bmatrix} \dot{\Psi}(x_1) & \cdots & \dot{\Psi}(x_m) \end{bmatrix}.$$

13.4. Bài toán least-squares cho generator

Ta muốn tìm ma trận L sao cho

$$\dot{\Psi}_X \approx L \Psi_X. \quad (29)$$

Least-squares:

$$L^* = \dot{\Psi}_X \Psi_X^\dagger. \quad (30)$$

Sau đó giải bài toán riêng:

$$Lw = \lambda w.$$

Từ đó có thể thu được xấp xỉ eigenfunctions của generator, và từ đó liên hệ tới Koopman semigroup.

14. Sai số xấp xỉ và hai nguồn sai số chính

Trong EDMD/GEDMD có hai nguồn xấp xỉ:

1. **Sai số do hữu hạn dictionary**: chỉ dùng d basis/lifting functions nên thực chất ta đang chiếu toán tử thật lên một không gian con hữu hạn chiều.
2. **Sai số do hữu hạn dữ liệu**: chỉ có m samples nên ta xấp xỉ các inner products / covariance objects bằng trung bình mẫu.

Với d cố định, sai số do lấy mẫu thường mang bản chất thống kê kiểu

$$\mathcal{O}\left(\frac{1}{\sqrt{m}}\right),$$

vì thuật toán cốt lõi là least-squares.

Nếu dùng các phương pháp kernel, ta có thể tránh việc giới hạn vào một dictionary hữu hạn tường minh, khi đó cấu phần lỗi do basis hữu hạn thay đổi bản chất.

15. Koopman mode decomposition

15.1. Ý tưởng

Giả sử ta đã tính được các eigenfunctions xấp xỉ ϕ_i của Koopman operator. Cho một observable bất kỳ $g(x)$, ta cố gắng biểu diễn nó thành tổ hợp của các eigenfunctions:

$$g(x) \approx \sum_{i=1}^r \alpha_i \phi_i(x). \quad (31)$$

Các hệ số α_i được gọi là **Koopman modes / coefficients** của observable g theo cơ sở eigenfunctions.

15.2. Lợi thế lớn

Vì ϕ_i là eigenfunctions:

$$\mathcal{K}\phi_i = \lambda_i \phi_i,$$

nên khi áp dụng toán tử n bước:

$$\mathcal{K}^n g \approx \sum_{i=1}^r \alpha_i \lambda_i^n \phi_i. \quad (32)$$

Điều này cực mạnh:

sau khi decomposed observable vào eigenbasis của Koopman, propagation theo thời gian trở nên gần như tầm thường: chỉ cần nhân thêm λ_i^n .

15.3. Mở rộng nhờ tính đại số của eigenfunctions

Nếu ϕ_i, ϕ_j là eigenfunctions với eigenvalues λ_i, λ_j , thì tích của chúng cũng là một eigenfunction:

$$\mathcal{K}(\phi_i \phi_j) = (\mathcal{K}\phi_i)(\mathcal{K}\phi_j) = \lambda_i \lambda_j \phi_i \phi_j. \quad (33)$$

Nói chung:

$$\phi_1^{k_1} \phi_2^{k_2} \dots \phi_r^{k_r} \quad (34)$$

cũng là eigenfunction với eigenvalue

$$\lambda_1^{k_1} \lambda_2^{k_2} \dots \lambda_r^{k_r}. \quad (35)$$

Nhờ đó ta có thể xây dựng một họ basis rất giàu từ một số nhỏ eigenfunctions ban đầu.

16. Ứng dụng của Koopman mode decomposition

16.1. Propagation of uncertainty

Giả sử $g(x)$ biểu diễn một phân bố bất định ban đầu hoặc một density ban đầu. Khi decomposed:

$$g(x) \approx \sum_i \alpha_i \phi_i(x),$$

thì sau n bước:

$$\mathcal{K}^n g(x) \approx \sum_i \alpha_i \lambda_i^n \phi_i(x).$$

Do đó, propagation of uncertainty có thể được tính rất hiệu quả.

16.2. Reachability

Trong robotics và control, ta quan tâm:

- từ một tập ban đầu, hệ có thể đi tới đâu?
- dưới điều khiển và nhiễu, tập các trạng thái có thể đạt tới là gì?

Koopman/PF viewpoint cho phép mã hóa các tập hoặc densities rồi đẩy chúng đi tới trước theo động lực học.

16.3. Safety

Nếu một vùng không an toàn phải tránh, thì trong ngôn ngữ occupancy:

ta muốn occupation measure của vùng đó bằng 0 hoặc rất nhỏ.

Đây là cầu nối rất đẹp giữa operator methods và safe control.

17. Xấp xỉ Perron–Frobenius từ Koopman

17.1. Trường hợp basis trực giao

Nếu basis/lifting functions là trực giao, thì trong hữu hạn chiều:

$$P = K^\top. \quad (36)$$

Ở đây:

- K : ma trận Koopman hữu hạn chiều,
- P : ma trận Perron–Frobenius hữu hạn chiều.

17.2. Trường hợp basis không trực giao

Nếu basis không trực giao, phải có chuẩn hóa theo Gram matrix:

$$P = G^{-1} K^T G, \quad (37)$$

trong đó

$$G = \frac{1}{m} \Psi_X \Psi_X^T. \quad (38)$$

Điều này rất quan trọng trong implementation thực tế.

18. Ví dụ Van der Pol oscillator và invariant measure

18.1. Động lực học

Van der Pol oscillator có:

- một equilibrium không ổn định,
- một stable limit cycle.

Mọi quỹ đạo đủ tổng quát cuối cùng đều hội tụ về limit cycle.

18.2. PF eigenfunction ứng với eigenvalue 1

Vì động học dài hạn tập trung trên stable limit cycle, nên eigenfunction của PF ứng với eigenvalue 1 phải được **support** trên limit cycle đó.

Nói trực giác:

- ngoài limit cycle, giá trị của invariant density phải gần 0,
- trên limit cycle, density là khác 0.

Do limit cycle là một tập đo bằng 0 trong mặt phẳng, invariant object chuẩn xác thường là một **measure** chứ không phải một hàm trơn theo nghĩa cổ điển.

18.3. Thông tin thời gian nằm trong measure không đều

Điểm rất hay là:

- hệ không chạy đều trên mọi đoạn của limit cycle,
- có đoạn nó di chuyển chậm hơn, nên quỹ đạo *ở lại lâu hơn*,
- có đoạn nó di chuyển nhanh hơn, nên quỹ đạo *ở lại ít hơn*.

Do đó invariant measure không chỉ nói *ở đâu* hệ tồn tại dài hạn, mà còn nói *nó ở đó nhiều hay ít*.

Đây chính là thông tin “occupation” và là mối nối tới ergodic theory.

19. Ergodicity và physical measure

19.1. Time average và space average

Một hệ được gọi là ergodic với respect to a measure μ nếu time average bằng space average:

$$\lim_{T \rightarrow \infty} \frac{1}{T} \int_0^T g(x(t)) dt = \int g(x) d\mu(x) \quad (39)$$

cho một lớp đủ rộng các observables g .

19.2. Không phải measure nào ergodic cũng “có ý nghĩa vật lý”

Ví dụ:

- hệ $\dot{x} = x$ có equilibrium không ổn định tại 0,
- về mặt hình thức, delta measure tại 0 có thể là invariant,
- nhưng nó không phải là một **physical measure**, vì quỹ đạo điển hình không hội tụ về đó.

Ngược lại, với $\dot{x} = -x$, delta measure tại 0 là physical, vì quỹ đạo điển hình thật sự hội tụ về 0.

19.3. Với Van der Pol

Measure supported trên stable limit cycle là một physical measure, vì ta thật sự thấy quỹ đạo mô phỏng tiến về nó.

20. Occupation measure

Occupation measure mô tả hệ dành bao nhiêu “thời gian” ở các vùng khác nhau của không gian trạng thái.

Nếu một vùng bị cấm về mặt an toàn, thì một safe behavior tương ứng với:

occupation của vùng đó bằng 0.

Nhờ đó:

- safety constraints có thể được diễn đạt bằng occupancy,
- control problems cũng có thể được viết lại bằng occupation measures,
- từ đó nhiều bài toán phi lồi gốc có thể được đưa về các bài toán lồi trong không gian measure/operator.

Đây là một trong những lợi thế rất mạnh của operator viewpoint đối với điều khiển.

21. Tại sao operator framework hữu ích cho control?

Một trong những phát biểu quan trọng của bài giảng là:

Khi viết bài toán điều khiển trong operator framework, ta có thể chuyển một bài toán phi lỗi trong state-space thành một bài toán lỗi trong space of measures/operators.

Đây là điểm rất đáng giá:

- dynamics gốc là phi tuyến,
- reachable sets, safety, uncertainty propagation đều khó trong state-space,
- nhưng có thể trở nên có cấu trúc hơn nhiều trong operator / measure space.

22. Tóm tắt thuật toán

22.1. DMD

1. Thu thập snapshots $x_1, \dots, x_m$.
2. Tạo ma trận X và X' .
3. Giải least-squares:

$$A^* = X'X^\dagger.$$

4. Tính eigenvalues/eigenvectors của A^* .

22.2. EDMD

1. Chọn dictionary $\psi_1, \dots, \psi_d$.
2. Tạo lifted data $\Psi_X, \Psi_{X'}$.
3. Tính

$$G = \frac{1}{m} \Psi_X \Psi_X^\top, \quad A = \frac{1}{m} \Psi_X \Psi_{X'}^\top.$$

4. Suy ra

$$K = G^{-1}A.$$

5. Từ eigenvectors của K , dựng eigenfunctions:

$$\phi_j(x) \approx w_j^\top \Psi(x).$$

22.3. GEDMD

1. Thu thập dữ liệu $(x_\ell, \dot{x}_\ell)$.
2. Chọn dictionary $\psi_1, \dots, \psi_d$.
3. Tính Ψ_X và $\dot{\Psi}_X$.
4. Giải

$$L^* = \dot{\Psi}_X \Psi_X^\dagger.$$

5. Tính eigenvalues/eigenvectors của L^* .

23. Những điểm tư tưởng cốt lõi cần nhớ

1. Hệ phi tuyến trong state-space có thể trở thành tuyến tính trong function space.
2. Koopman operator tác động lên observables.
3. Perron–Frobenius operator tác động lên densities/measures.
4. Eigenfunction của PF với eigenvalue 1 mang thông tin về steady-state / invariant distribution.
5. Nếu có nhiều steady states, PF có thể có nhiều eigenfunctions ứng với eigenvalue 1.
6. DMD là least-squares trên dữ liệu có tính thời gian.
7. SVD/POD tìm modes giàu năng lượng; DMD tìm modes quan trọng về mặt động lực học.
8. EDMD lift dữ liệu bằng observables phi tuyến để xấp xỉ Koopman tốt hơn.
9. GEDMD làm điều tương tự cho generator trong continuous time.
10. Koopman mode decomposition biến propagation of observables thành bài toán gần như tuyến tính hoàn toàn theo các eigenvalues.
11. Duality giữa Koopman và PF cho phép đi từ một bên sang bên kia qua chuyển vị / Gram normalization.
12. Invariant measure và occupation measure là chìa khóa nối operator theory với ergodic theory, safety, reachability và control design.

24. Kết luận

Bài giảng này cho thấy một bức tranh rất đẹp:

- **Differential geometry** cho ta ngôn ngữ đẹp để hiểu cấu trúc của hệ phi tuyến,
- nhưng thường khó tính toán trực tiếp trong các bài toán lớn.
- **Operator-theoretic methods** thay vào đó chấp nhận làm việc trong không gian hàm và dùng dữ liệu để xây dựng xấp xỉ hữu hạn chiều.

Điều đặc biệt mạnh ở đây là:

lý thuyết phía sau thì vô hạn chiều và rất sâu, nhưng thuật toán lõi lại có thể quy về một bài toán least-squares rất cơ bản.

Chính nhờ đó, DMD, EDMD, GEDMD trở thành những công cụ thực tế rất mạnh cho:

- phân tích dữ liệu động lực học,
- model reduction,
- uncertainty propagation,
- invariant measure computation,
- reachability,
- safety,
- và control design.

Tư tưởng quan trọng nhất của toàn bài có thể tóm lại trong một câu:

Thay vì cố giải trực tiếp hệ phi tuyến trong state-space, ta học cách đẩy observables hoặc densities qua một toán tử tuyến tính trong function space, rồi khai thác cấu trúc phổ của toán tử đó.